

字节交流-260814

讨论事务

PTO相关

1、针对上一版的性能问题，我们修改了端侧 Vector 指令的同步机制，同时对 Sigmoid-Prefill 用例做了改写，使用了 Ping-Pong Buffer 的机制，复测性能提升 35% 左右；

2、PTO IR 本身具备大部分硬件控制力，它允许用户自己分配地址，也支持用户自己做指令同步。但是使用这些能力也意味着代码的兼容性会更差。所以这里的性能和兼容性的考量是什么样？

倾向性能，兼容性中台吃掉，但不要每代都加班

3、跨平台兼容性的具体要求是什么？（多少代之内兼容，后向兼容，还是可以通过版本控制兼容性）
同上

4、是否需要手工控制片上分配与多级流水（--pto-level=level3 可关闭 PlanMemory 与 InsertSync）的能力，若自己想控，这条路现成，需要确认是否需要？

需要，兼容性自己吃掉

5、从 Triton 降级到 PTO IR 的路径是什么样的？

triton->tritonir->linalgir->ascir（字节自己写MLIR方言）
->ptoir

6、是否方便提供软件架构图以及软件流程图，帮忙发送一下

7、“性能达标”的量化定义：追平手写 cce，还是追平同规格安卓上的 QNN？可接受 gap 多少，按单算子还是整网 token/s 验收

极致性能

8、PTO 这个 tile 级虚拟 ISA 抽象层级是否满足要求（社区文档是否暴露足够多的信息来满足性能要求）

社区文档抽象层次很高，需要更低的抽象层次，达成最佳性能

9、集成和部署形态：kernel bin 如何进入推理引擎（预编译 .o/.so、静态注册、运行时 JIT）；

外部ddk自定义算子转成omc。预编译 .o/.so

10、包大小、启动时延、内存峰值是否有硬指标；

当前无法提出具体约束，只能说越小越好；但是AI模型不占初始包体，后续下载

eg: 0.5B < 200M

启动时延：700ms?? 帮忙确认一下具体指标

算子相关

1、华为CCE算子性能最高，比ASC高20%，具体是什么算子，CCE算子指的是DDK里自带的预置算子库吗

- 反量化算子使用reg compute，但是没有极致优化，比如vf融合
- cube算子，使用mad intrinisc接口
- 全是自定义算子

2、算子对底层信息敏感，对于模型推理性能影响大：相同模型，使用当前的手写算子，9020推理比9030高20%以上，decode 22->18

1) 什么模型

2) 用的外部ddk吗，是否使用了预置算子，是否使用了量化，使用了什么量化

3) 0.5B LLM，4bit反量化到16bit，fp16计算；全部算子都是自己写的，需要代码才能判断，帮忙提供一下代码

3、9030相关API缺失，这个是指什么API -- ASC 9030应该开放了ASC编程能力。资料未刷新

1) 资料未刷新

字节诉求

1、确定好端侧AI算子编译的策略，保证生成高性能算子。强诉求，需要能开放能力、定好时间节点

1) 是否一定要走Triton编译这一套路径，能否接受ASC算子编程、Pypto算子编程 -- 走triton

triton->tritonir->linalgir->ascir

->ptoir

2) 对兼容性的要求是怎么样的，DSA编程其实多多少少会有一些适配修改.

2、PTO性能优化空间，进度偏慢，仅能达到26%~50%，

1) 这个指什么算子 -- vector类算子

2) pto还是ptoas -- ptoas

3、8gen2、8gen3 性能非常优秀，decode分别70~86token/s 再帮忙确认一下对于平台是否正确以及prefill性能

1) 这个大概是什么规模的LLM，用了什么量化 -- 0.5B，4bit；反量化int16计算

2) 高通的代际兼容性如何做到的，是一套代码，8gen2/3通用吗；没有变化，但是性能还需要调优

3) 高通的动态shape；也是多组kernel

结论：

- 【开放诉求】提前拿到API编程文档
- 动态shape+在线编译：预置多组shape，高通也是如此，目前还没有看到有使用动态shape的；
 - 从竞品和业务角度看看是否真的需要；
 - 有分chunk、分档等手段来做
- 【开放诉求】控内存：量化对端侧的重要性非常高，1.25bit、2、3bit？
- 性能更重要，兼容性由中台团队吃掉，但代际差异不宜太大，有文档说明
- 【人力诉求】AscendC量化算子实现需要有人支撑（930灰度，达成性能和功能诉求）
- 集成方式：外部ddk自定义ASC算子通路
- 【开放诉求】profiling工具：基于model开发和pmu开放
- 【人力诉求】文档对接诉求：定一个时间节点和接口人

Agentic编程：

模型预置语料

自闭环能力：工具、资料